

DOCUMENTO MAESTRO 13

# Inteligencia artificial aplicada a la investigacion: copilotos, agentes, automatizacion, evaluacion y gobernanza

Sistema responsable para aumentar la capacidad cientifica sin delegar la integridad del Semillero SIPRAI

Universidad Nacional de Colombia - Sede Manizales | Coordinacion: Nelson Aristizabal Lopez | Version 1.0 - junio de 2026

**Principio rector:** la IA puede ampliar la capacidad de buscar, analizar, programar, visualizar y comunicar; no puede asumir la responsabilidad cientifica, etica ni autoral. Toda automatizacion debe conservar evidencia, supervision y posibilidad de detenerse.

|          |             |       |        |              |            |             |             |
|----------|-------------|-------|--------|--------------|------------|-------------|-------------|
| PROBLEMA | CASO DE USO | DATOS | MODELO | HERRAMIENTAS | EVALUACION | SUPERVISION | APRENDIZAJE |
|----------|-------------|-------|--------|--------------|------------|-------------|-------------|

| Campo               | Definicion                                                                                                                               |
|---------------------|------------------------------------------------------------------------------------------------------------------------------------------|
| Naturaleza          | Manual academico-operativo, protocolo, plantillas y base de conocimiento para el GPT mentor.                                             |
| Aplicacion          | Copilotos, asistentes de conocimiento, RAG, agentes con herramientas, automatizacion, programacion, analisis, escritura y transferencia. |
| Gobernanza          | NIST AI RMF y perfil de IA generativa, UNESCO, principios OCDE, ISO/IEC 42001, normativa aplicable y politicas institucionales.          |
| Calidad             | Evaluacion especifica por tarea, datos y contexto; pruebas antes de uso; vigilancia despues del despliegue.                              |
| Resultado esperado  | Flujos de IA trazables, seguros, evaluados, reproducibles y con control humano proporcional al riesgo.                                   |
| Documento siguiente | 14 - Plantillas maestras, checklists, matrices y formatos operativos SIPRAI.                                                             |

## 0. Control del documento y advertencias

Este manual no presupone que un modelo sea confiable por su popularidad, fluidez o novedad. Las capacidades, politicas, costos y condiciones de tratamiento de datos cambian; por ello, todo sistema debe registrar proveedor, modelo, version o fecha, configuracion, fuentes, pruebas y responsable.

| Marco vigente                    | Aplicacion SIPRAI                                                                    | Estado/precaucion                                      |
|----------------------------------|--------------------------------------------------------------------------------------|--------------------------------------------------------|
| NIST AI RMF 1.0                  | Gobernar, mapear, medir y gestionar riesgos durante el ciclo de vida.                | Marco voluntario publicado en 2023.                    |
| NIST AI 600-1                    | Riesgos y acciones especificas para IA generativa.                                   | Perfil final publicado en julio de 2024.               |
| UNESCO Etica de IA               | Derechos humanos, agencia, inclusion, sostenibilidad y gobernanza.                   | Recomendacion global adoptada en 2021.                 |
| Principios OCDE                  | IA innovadora y confiable; transparencia, robustez y rendicion de cuentas.           | Actualizados en mayo de 2024.                          |
| ISO/IEC 42001:2023               | Sistema de gestion organizacional para IA.                                           | Norma certificable voluntaria; no reemplaza la ley.    |
| Reglamento UE 2024/1689          | Enfoque basado en riesgos y obligaciones para actores/sistemas dentro de su alcance. | Verificar aplicabilidad y calendario antes de decidir. |
| Colombia CONPES 4144 de 2025     | Politica nacional de IA y hoja de ruta hasta 2030.                                   | Politica publica, no ley general de IA.                |
| SIC Circular Externa 002 de 2024 | Tratamiento de datos personales en sistemas de IA.                                   | Aplicar junto con Ley 1581 y normas relacionadas.      |
| Proyecto de ley colombiano de IA | Propuesta regulatoria con enfoque etico y de riesgo.                                 | No presentarlo como ley vigente sin verificacion.      |

Toda afirmacion normativa debe verificarse nuevamente antes de desplegar un sistema, publicar una politica o tratar datos personales.

## 1. Taxonomia de IA para investigacion

| Categoria                   | Que hace                                                    | Ejemplo de investigacion                             |
|-----------------------------|-------------------------------------------------------------|------------------------------------------------------|
| Modelo predictivo           | Estima clase, valor o riesgo a partir de datos.             | Predecir atraso de proyectos.                        |
| Modelo generativo           | Produce texto, imagen, audio, codigo u otros contenidos.    | Borrador de sintesis o codigo.                       |
| Copiloto                    | Asiste a una persona dentro de una tarea y espera revision. | Depurar un script o mejorar una tabla.               |
| Asistente de conocimiento   | Responde con base en un corpus definido.                    | Consultar documentos del curso/semillero.            |
| RAG                         | Recupera fragmentos y los incorpora a la generacion.        | Responder con citas a protocolos.                    |
| Agente                      | Persigue una meta, selecciona acciones y usa herramientas.  | Buscar, clasificar, registrar y proponer decisiones. |
| Sistema multiagente         | Distribuye roles y coordinacion entre agentes.              | Agente buscador, revisor y auditor.                  |
| Automatizacion determinista | Ejecuta reglas sin razonamiento generativo.                 | Renombrar, validar formatos y calcular indicadores.  |

| Categoría     | Que hace                                | Ejemplo de investigacion                      |
|---------------|-----------------------------------------|-----------------------------------------------|
| IA multimodal | Procesa o genera varios tipos de datos. | Analizar imagen, audio y texto de una sesion. |

## 1.1 Regla de seleccion

**Use la tecnologia menos autonoma y mas verificable que resuelva el problema. No convierta una regla simple en un agente ni una consulta estable en una cadena compleja.**

## 2. Copiloto, automatizacion y agente: diferencias

| Dimension    | Copiloto                               | Automatizacion                 | Agente                                                       |
|--------------|----------------------------------------|--------------------------------|--------------------------------------------------------------|
| Iniciativa   | Responde a solicitudes humanas.        | Ejecuta flujo predefinido.     | Selecciona pasos para alcanzar una meta.                     |
| Flexibilidad | Alta en dialogo.                       | Baja/media segun reglas.       | Alta, con mayor variabilidad.                                |
| Riesgo       | Depende de tarea y uso.                | Errores repetibles a escala.   | Errores encadenados y acciones no previstas.                 |
| Control      | Revision por salida.                   | Pruebas y monitoreo del flujo. | Permisos, limites, aprobaciones y observabilidad.            |
| Uso ideal    | Pensar, redactar, programar, explorar. | Tareas estables y repetitivas. | Procesos abiertos con herramientas y decisiones reversibles. |

## 2.1 Escala de autonomia

| Nivel | Descripcion                                                     | Aprobacion                                                              |
|-------|-----------------------------------------------------------------|-------------------------------------------------------------------------|
| A0    | Sin IA o solo calculo determinista.                             | Procedimiento normal.                                                   |
| A1    | IA sugiere; humano ejecuta.                                     | Revision de cada salida relevante.                                      |
| A2    | IA prepara artefacto; humano aprueba antes de usar.             | Puerta obligatoria.                                                     |
| A3    | IA ejecuta acciones reversibles dentro de limites.              | Aprobacion por lote y monitoreo.                                        |
| A4    | IA ejecuta multiples pasos con aprobaciones en puntos criticos. | Gobernanza reforzada.                                                   |
| A5    | Alta autonomia e impacto.                                       | No autorizado en SIPRAI para decisiones irreversibles o de alto riesgo. |

## 3. Casos de uso a lo largo del ciclo de investigacion

| Fase     | Usos permitidos con control                      | Riesgos                                    |
|----------|--------------------------------------------------|--------------------------------------------|
| Agenda   | Mapear preguntas, actores, fuentes y tendencias. | Sesgos de popularidad y omision.           |
| Problema | Contrastar formulaciones y supuestos.            | Redactar problema plausible sin evidencia. |

| Fase          | Usos permitidos con control                        | Riesgos                                      |
|---------------|----------------------------------------------------|----------------------------------------------|
| Revision      | Generar terminos, deduplicar, priorizar y resumir. | Referencias inventadas y exclusiones falsas. |
| Protocolo     | Revisar coherencia, listas y riesgos.              | Afirmar cumplimiento sin verificacion.       |
| Instrumentos  | Proponer items, escenarios y lenguaje.             | Validez aparente, sesgo cultural.            |
| Campo         | Transcribir, traducir y clasificar incidencias.    | Privacidad y perdida de matices.             |
| Analisis QUAN | Generar codigo, diagnosticos y visuales.           | Errores estadisticos convincentes.           |
| Analisis QUAL | Buscar segmentos, proponer codigos y preguntas.    | Delegar interpretacion e inventar citas.     |
| Mixtos        | Construir joint displays y detectar discrepancias. | Completar vacios de forma ficticia.          |
| Escritura     | Estructura, claridad, tablas y traduccion.         | Plagio, citas falsas y homogeneizacion.      |
| Transferencia | Adaptar productos a usuarios.                      | Simplificar en exceso o descontextualizar.   |

## 4. Clasificacion de riesgo por tarea

| Nivel         | Ejemplos                                                                                                      | Controles                                                                        |
|---------------|---------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------|
| Verde - bajo  | Lluvia de ideas, estilo, formato, codigo de prueba con datos ficticios.                                       | Revision humana y no ingresar datos sensibles.                                   |
| Ambar - medio | Resumen de fuentes, traduccion, transcripcion, codigo con datos reales no sensibles, clasificacion.           | Pruebas, muestra de auditoria, registro y aprobacion.                            |
| Rojo - alto   | Seleccion de participantes, decisiones academicas, evaluacion individual, datos sensibles, acciones externas. | Evaluacion de impacto, autorizacion, alternativas, doble control y minimizacion. |
| Prohibido     | Fabricar datos, referencias o participantes; suplantar autoria; decisiones irreversibles sin humano.          | Detener, registrar incidente y corregir.                                         |

### 4.1 Variables de riesgo

- Impacto potencial sobre personas, derechos, reputacion o decisiones.
- Sensibilidad y volumen de datos.
- Autonomia, conectividad y reversibilidad de acciones.
- Opacidad del modelo y posibilidad de auditoria.
- Probabilidad de error y dificultad para detectarlo.
- Dependencia del proveedor y cambios de modelo.
- Exposicion a ataques, inyeccion de instrucciones o contenido malicioso.

## 5. Ciclo de vida de un sistema de IA para investigacion

|           |                |         |        |         |           |            |         |
|-----------|----------------|---------|--------|---------|-----------|------------|---------|
| DESCUBRIR | EVALUAR RIESGO | DISENAR | PROBAR | APROBAR | DESPLEGAR | MONITOREAR | RETIRAR |
|-----------|----------------|---------|--------|---------|-----------|------------|---------|

| Etapa      | Producto minimo                                                         |
|------------|-------------------------------------------------------------------------|
| Descubrir  | Problema, usuario, tarea, valor y alternativa sin IA.                   |
| Riesgo     | Clasificacion, datos, impactos, amenazas y responsable.                 |
| Diseno     | Arquitectura, modelo, herramientas, prompts, permisos y logs.           |
| Prueba     | Dataset de evaluacion, rubrica, linea base, adversariales y resultados. |
| Aprobacion | Criterios de salida, limites, divulgacion y plan de incidentes.         |
| Despliegue | Version congelada, acceso, soporte y monitoreo.                         |
| Monitoreo  | Calidad, deriva, costo, quejas, fallos y reevaluacion.                  |
| Retiro     | Exportacion, archivo, revocacion de credenciales y lecciones.           |

## 6. Gobernanza con NIST AI RMF

| Funcion | Aplicacion en SIPRAI                                                                           |
|---------|------------------------------------------------------------------------------------------------|
| GOVERN  | Políticas, roles, cultura, inventario, autorizaciones, rendicion de cuentas y mejora.          |
| MAP     | Contexto, usuarios, datos, impactos, dependencias, actores y limites del uso.                  |
| MEASURE | Evaluaciones, metricas, pruebas, incertidumbre, sesgo, privacidad, seguridad y explicabilidad. |
| MANAGE  | Priorizar riesgos, implementar controles, monitorear, responder a incidentes y retirar.        |

### 6.1 Atributos de confianza

| Atributo                           | Pregunta operacional                                      |
|------------------------------------|-----------------------------------------------------------|
| Validez y confiabilidad            | ¿Funciona de forma suficientemente estable para la tarea? |
| Seguridad                          | ¿Evita fallos que causen dano?                            |
| Proteccion y resiliencia           | ¿Resiste ataques, errores y cambios?                      |
| Rendicion de cuentas/transparencia | ¿Se conocen responsables, limites y registros?            |
| Explicabilidad/interpretabilidad   | ¿Puede comprenderse lo necesario para usar o impugnar?    |
| Privacidad                         | ¿Minimiza y protege datos personales?                     |
| Equidad con sesgo gestionado       | ¿Los errores e impactos se distribuyen injustamente?      |

## 7. Sistema de gestion de IA

ISO/IEC 42001:2023 proporciona una estructura organizacional para establecer, implementar, mantener y mejorar continuamente un sistema de gestion de IA. SIPRAI adopta su logica sin afirmar certificacion.

| Componente         | Evidencia                                                              |
|--------------------|------------------------------------------------------------------------|
| Contexto y alcance | Inventario de sistemas, actores, requisitos y fronteras.               |
| Liderazgo          | Politica, responsabilidades y recursos.                                |
| Planificacion      | Riesgos, oportunidades, objetivos y controles.                         |
| Soporte            | Competencias, informacion documentada, comunicacion e infraestructura. |
| Operacion          | Ciclo de vida, datos, proveedores y cambios.                           |
| Evaluacion         | Indicadores, auditorias y revision por la direccion.                   |
| Mejora             | Incidentes, no conformidades y acciones correctivas.                   |

## 8. Arquitectura de un copiloto de investigacion

| Capa         | Funcion                                           | Control                                             |
|--------------|---------------------------------------------------|-----------------------------------------------------|
| Interfaz     | Recibe solicitud y presenta evidencia.            | Identidad, advertencias y accesibilidad.            |
| Orquestacion | Decide flujo, herramientas y formato.             | Políticas y límites.                                |
| Modelo       | Interpreta y genera.                              | Version, temperatura/configuracion y restricciones. |
| Conocimiento | Corpus, bases, metadatos y permisos.              | Procedencia, vigencia y calidad.                    |
| Herramientas | Busqueda, calculo, codigo, archivos y conectores. | Lista permitida y permisos minimos.                 |
| Memoria      | Estado de sesion o perfil.                        | Necesidad, retencion y borrado.                     |
| Evaluacion   | Pruebas, logs y feedback.                         | Dataset, rubrica y umbrales.                        |
| Supervision  | Aprobaciones, escalamiento e incidentes.          | Responsable humano.                                 |

## 9. Prompting como especificacion, no como magia

| Elemento      | Contenido                                                |
|---------------|----------------------------------------------------------|
| Rol funcional | Tarea y limites, no personalidad grandiosa.              |
| Objetivo      | Resultado observable y usuario.                          |
| Contexto      | Datos necesarios, definiciones y restricciones.          |
| Fuentes       | Que puede usar y como citar.                             |
| Proceso       | Pasos, verificaciones y herramientas.                    |
| Salida        | Esquema, campos, longitud y idioma.                      |
| Criterios     | Rubrica de calidad y umbrales.                           |
| Incertidumbre | Como reconocer faltantes y abstenerse.                   |
| Seguridad     | Datos prohibidos, acciones no permitidas y escalamiento. |

| Elemento | Contenido                             |
|----------|---------------------------------------|
| Ejemplos | Casos positivos, negativos y limites. |

## 9.1 Anti-patrones

- Pedir que actue como el mayor experto y asumir que eso produce exactitud.
- Incluir cien reglas contradictorias sin prioridad.
- Solicitar citas sin exigir fuentes verificables.
- Usar un ejemplo sesgado como unica referencia.
- Cambiar prompts despues de ver resultados y presentarlos como evaluacion previa.

## 10. RAG y asistentes fundamentados en fuentes

| INGESTA | EXTRACCION | FRAGMENTACION | METADATOS | INDICE | RECUPERACION | RE-RANKING | GENERACION | CITAS | EVALUACION |
|---------|------------|---------------|-----------|--------|--------------|------------|------------|-------|------------|
|---------|------------|---------------|-----------|--------|--------------|------------|------------|-------|------------|

| Componente    | Decision                                              |
|---------------|-------------------------------------------------------|
| Corpus        | Autoridad, cobertura, permisos, versiones y vigencia. |
| Extraccion    | Texto, tablas, imagenes, OCR y errores.               |
| Chunking      | Unidad semantica, solapamiento y contexto.            |
| Metadatos     | Documento, seccion, fecha, tipo, acceso y version.    |
| Retrieval     | Consulta, filtros, top-k y metodo hibrido.            |
| Reranking     | Ordenar por relevancia con costo y latencia.          |
| Contexto      | Presupuesto, duplicados y contradicciones.            |
| Respuesta     | Solo afirmar lo sustentado, citar y reconocer vacios. |
| Actualizacion | Reindexar, retirar obsoletos y preservar historial.   |

### 10.1 Evaluaciones RAG

| Dimension    | Metrica/prueba                                                     |
|--------------|--------------------------------------------------------------------|
| Recuperacion | Recall de evidencia relevante, precision, MRR/nDCG cuando proceda. |
| Groundedness | Proporcion de afirmaciones respaldadas por contexto.               |
| Citas        | Precision de cita, cobertura y correspondencia con la afirmacion.  |
| Respuesta    | Correccion, completitud, relevancia y abstencion.                  |
| Robustez     | Parafrasis, consultas ambiguas, documentos conflictivos y ruido.   |
| Seguridad    | Prompt injection, documentos maliciosos y exfiltracion.            |

**RAG reduce algunos errores, pero no garantiza verdad. Una respuesta puede citar una fuente irrelevante, interpretar mal el texto o ignorar evidencia contradictoria.**

## 11. Agentes y uso de herramientas

| Componente de agente | Pregunta de diseno                                       |
|----------------------|----------------------------------------------------------|
| Meta                 | ¿Es concreta, verificable y limitada?                    |
| Planificacion        | ¿Puede descomponer sin crear tareas innecesarias?        |
| Herramientas         | ¿Cuales estan autorizadas y con que permisos?            |
| Estado/memoria       | ¿Que conserva y durante cuanto tiempo?                   |
| Observacion          | ¿Como comprueba que una accion ocurrio?                  |
| Critica              | ¿Existe verificador independiente o reglas?              |
| Aprobacion           | ¿Que acciones requieren humano?                          |
| Parada               | ¿Cuando se detiene por exito, costo, tiempo o riesgo?    |
| Recuperacion         | ¿Que hace ante error parcial o herramienta indisponible? |
| Auditoria            | ¿Se registran decisiones, inputs, outputs y acciones?    |

### 11.1 Principio de minimo privilegio

- Acceso de lectura antes que escritura.
- Entorno de prueba antes que produccion.
- Credenciales temporales y especificas.
- Aprobacion para enviar, borrar, publicar o modificar registros.
- Limites de costo, tiempo, iteraciones y volumen.
- Boton de detencion y revocacion de credenciales.

## 12. Amenazas en sistemas generativos y agentes

| Amenaza                   | Ejemplo                                       | Control                                               |
|---------------------------|-----------------------------------------------|-------------------------------------------------------|
| Prompt injection          | Documento intenta cambiar instrucciones.      | Separar datos de instrucciones, filtros y permisos.   |
| Indirect prompt injection | Contenido web malicioso dentro de una fuente. | Sanitizar, aislar y no conceder acciones automaticas. |
| Exfiltracion              | Respuesta revela datos o secretos.            | Minimizacion, controles de salida y pruebas.          |
| Tool misuse               | Agente usa herramienta fuera de proposito.    | Allowlist, esquemas y aprobaciones.                   |
| Hallucination             | Inventa hechos, citas o acciones.             | Grounding, verificacion y abstencion.                 |
| Overreliance              | Humano acepta por fluidez.                    | Entrenamiento, friccion y evidencia.                  |
| Data poisoning            | Corpus contiene informacion manipulada.       | Procedencia, reputacion y monitoreo.                  |
| Model drift/change        | Proveedor cambia comportamiento.              | Versionado, pruebas de regresion y fallback.          |
| Denial of wallet          | Bucles consumen recursos.                     | Presupuestos, timeout y maximo de pasos.              |

| Amenaza             | Ejemplo                       | Control                                  |
|---------------------|-------------------------------|------------------------------------------|
| Memoria contaminada | Guarda dato falso o sensible. | Politica de memoria, revision y borrado. |

## 13. Datos, privacidad y confidencialidad

| Pregunta      | Decision requerida                                         |
|---------------|------------------------------------------------------------|
| Necesidad     | ¿La tarea requiere esos datos?                             |
| Base/permiso  | ¿Existe autorizacion, contrato o fundamento?               |
| Proveedor     | ¿Entrena con datos? ¿Donde procesa? ¿Quien accede?         |
| Sensibilidad  | ¿Personal, confidencial, propiedad intelectual o secreto?  |
| Minimizacion  | ¿Puede anonimizarse, sintetizarse o procesarse localmente? |
| Retencion     | ¿Cuanto conserva prompts, archivos y logs?                 |
| Transferencia | ¿Existen transferencias nacionales o internacionales?      |
| Seguridad     | ¿Cifrado, MFA, control de acceso y registro?               |
| Derechos      | ¿Como se atiende acceso, correccion, supresion o retiro?   |
| Incidente     | ¿Quien responde y como se notifica?                        |

### 13.1 Colombia

El uso de IA con datos personales debe cumplir el regimen colombiano de proteccion de datos. La Circular Externa 002 de 2024 de la SIC ofrece lineamientos especificos para tratamiento de datos personales en sistemas de IA; su aplicacion debe articularse con la Ley 1581 de 2012, decretos, politicas institucionales y obligaciones contractuales.

## 14. Integridad cientifica, autoria y divulgacion

| Regla            | Aplicacion                                                                                    |
|------------------|-----------------------------------------------------------------------------------------------|
| Autoria humana   | La IA no cumple responsabilidad, aprobacion ni rendicion de cuentas; no se lista como autora. |
| Responsabilidad  | Los autores verifican exactitud, originalidad, citas, permisos y ausencia de plagio.          |
| Divulgacion      | Describir herramienta y uso cuando sea material para el trabajo.                              |
| Trazabilidad     | Conservar prompts/configuracion relevantes, version/fecha y revisiones.                       |
| Confidencialidad | No cargar manuscritos o revisiones confidenciales en servicios no autorizados.                |
| Citas            | Citar fuentes originales; no citar al chatbot como autoridad de hechos.                       |
| Imagen/audio     | Declarar generacion o edicion cuando sea sustantiva y verificar derechos.                     |

| Regla        | Aplicacion                                      |
|--------------|-------------------------------------------------|
| Datos/codigo | Distinguir material real, simulado y sintetico. |

### 14.1 Declaracion modelo

**Se utilizo [herramienta/modelo, version o fecha] para [tarea]. Los autores revisaron y verificaron [aspectos], conservaron [registros] y asumen responsabilidad total por el contenido, las fuentes, los analisis y las conclusiones.**

## 15. Evaluacion de sistemas de IA - TEVV

La evaluacion, prueba, verificacion y validacion debe ser sociotecnica: examina el sistema, los usuarios, el proceso, el contexto y los impactos. La evaluacion no termina con un benchmark general.

| Termino      | Pregunta                                                  |
|--------------|-----------------------------------------------------------|
| Testing      | ¿Que ocurre bajo casos normales, limites y adversariales? |
| Evaluation   | ¿Que tan bien cumple objetivos y criterios?               |
| Verification | ¿Se construyo conforme a especificaciones y controles?    |
| Validation   | ¿Es adecuado para el uso real y sus usuarios?             |
| Monitoring   | ¿Sigue siendo adecuado despues del despliegue?            |

### 15.1 Piramide de evaluacion

| Nivel          | Prueba                                                     |
|----------------|------------------------------------------------------------|
| Unidad         | Prompts, funciones, parsers, herramientas y formatos.      |
| Componente     | Retrieval, modelo, clasificador, memoria y guardrails.     |
| Sistema        | Flujo completo y dependencias.                             |
| Humano-sistema | Comprension, error de uso, carga, confianza y supervision. |
| Campo          | Desempeno en contexto, impactos, equidad y sostenibilidad. |

## 16. Plan de evaluacion por tarea

| Dimension        | Ejemplos de metricas                                      |
|------------------|-----------------------------------------------------------|
| Exactitud        | Respuesta correcta, error absoluto, concordancia con oro. |
| Compleitud       | Cobertura de criterios o evidencia necesaria.             |
| Factualidad      | Afirmaciones verificadas y contradicciones.               |
| Groundedness     | Afirmaciones respaldadas por fuentes proporcionadas.      |
| Calidad de citas | Precision, cobertura y ubicacion.                         |

| Dimension     | Ejemplos de metricas                                 |
|---------------|------------------------------------------------------|
| Utilidad      | Tiempo ahorrado, calidad de decision y carga humana. |
| Robustez      | Parafrasis, ruido, idiomas, formatos y cambios.      |
| Equidad       | Errores y utilidad por grupos/contextos.             |
| Seguridad     | Tasa de ataques exitosos, fuga y acciones indebidas. |
| Confiabilidad | Variacion entre ejecuciones y disponibilidad.        |
| Eficiencia    | Latencia, costo, energia/recursos y tokens.          |
| Abstencion    | Reconoce falta de evidencia y escala correctamente.  |

## 16.1 Comparadores

- Proceso humano actual.
- Regla o busqueda simple.
- Modelo mas pequeno o local.
- Modelo anterior.
- Experto independiente.
- Resultado sin RAG frente a RAG.
- Agente frente a flujo con aprobaciones.

## 17. Construcción de un conjunto de evaluación

| Componente          | Regla                                                    |
|---------------------|----------------------------------------------------------|
| Casos reales        | Representar tareas y distribucion de uso.                |
| Casos limite        | Ambigüedad, falta de datos y contradicción.              |
| Casos adversariales | Inyección, datos sensibles y instrucciones conflictivas. |
| Casos negativos     | La respuesta correcta es abstenerse o rechazar.          |
| Diversidad          | Idiomas, estilos, perfiles, documentos y niveles.        |
| Gold standard       | Criterio creado/revisado por expertos con procedimiento. |
| Rubrica             | Dimensiones observables, anclas y desempate.             |
| Separacion          | Desarrollo, validacion y prueba final.                   |
| Version             | Congelar conjunto y controlar contaminacion.             |
| Actualizacion       | Agregar fallos reales sin borrar historia.               |

## 18. Evaluación humana

| Decision   | Buena practica                                  |
|------------|-------------------------------------------------|
| Jueces     | Competencia pertinente y conflictos declarados. |
| Cegamiento | Ocultar modelo/condicion cuando sea posible.    |

| Decision     | Buena practica                                      |
|--------------|-----------------------------------------------------|
| Rubrica      | Criterios y ejemplos antes de evaluar.              |
| Piloto       | Calibrar y resolver ambigüedades.                   |
| Muestreo     | Casos aleatorios y de alto riesgo.                  |
| Acuerdo      | Reportar y analizar desacuerdos cuando corresponda. |
| Preferencia  | No confundir agrado con correccion.                 |
| Fatiga       | Bloques, orden aleatorio y pausas.                  |
| Adjudicacion | Tercer evaluador o consenso registrado.             |
| Etica        | Proteger datos y bienestar de evaluadores.          |

**Un modelo puede obtener alta preferencia por escribir con fluidez y aun producir mas errores factuales. Las rubricas deben separar estilo, verdad, evidencia y utilidad.**

## 19. Evaluacion automatica y juez basado en IA

| Uso                      | Control                                                       |
|--------------------------|---------------------------------------------------------------|
| Formato/esquema          | Validacion determinista preferida.                            |
| Coincidencia exacta      | Adecuada para respuestas cerradas.                            |
| Metricas semanticas      | Complementar con auditoria humana.                            |
| LLM-as-judge             | Calibrar contra expertos, ocultar identidad y revisar sesgos. |
| Pruebas de regresion     | Ejecutar tras cambios de modelo, corpus o prompt.             |
| Red teaming automatizado | Generar ataques, pero verificar cobertura y falsos negativos. |

### 19.1 Riesgos del juez de IA

- Preferencia por respuestas largas o su propio estilo.
- Sensibilidad al orden.
- Error compartido con el modelo evaluado.
- Inconsistencia entre ejecuciones.
- Rubricas interpretadas de forma superficial.
- Fuga del conjunto de evaluacion.

## 20. Seleccion de modelo y proveedor

| Criterio  | Preguntas                                     |
|-----------|-----------------------------------------------|
| Capacidad | ¿Resuelve la tarea y el idioma con evidencia? |
| Contexto  | ¿Maneja longitud y archivos necesarios?       |
| Modalidad | ¿Texto, imagen, audio, codigo o herramientas? |

| Criterio                | Preguntas                                           |
|-------------------------|-----------------------------------------------------|
| Privacidad              | ¿Políticas, residencia, retención y entrenamiento?  |
| Seguridad               | ¿Certificaciones, controles, logs y respuesta?      |
| Control                 | ¿Versión fija, parámetros y opciones de despliegue? |
| Costo                   | ¿Costo por uso, evaluación, supervisión y cambio?   |
| Latencia/disponibilidad | ¿Cumple necesidad y tiene fallback?                 |
| Transparencia           | ¿Documenta límites, cambios y uso aceptable?        |
| Sostenibilidad          | ¿Modelo menor puede lograr resultado suficiente?    |
| Portabilidad            | ¿Puede migrarse sin rehacer todo el sistema?        |

## 20.1 Benchmark local

**Seleccione con una prueba local de tareas SIPRAI. Los rankings generales no representan necesariamente el idioma, los documentos, los riesgos ni el presupuesto del semillero.**

## 21. Asistentes de conocimiento para docencia e investigación

| Elemento       | Decisión                                                                 |
|----------------|--------------------------------------------------------------------------|
| Propósito      | Consulta, tutor, evaluador, generador de casos o gestor de conocimiento. |
| Audiencia      | Miembros, estudiantes, docentes, aliados o público.                      |
| Corpus         | Fuentes aprobadas, versión y propiedad intelectual.                      |
| Comportamiento | Que responde, como enseña y cuando se abstiene.                          |
| Citas          | Evidencia visible y localizable.                                         |
| Evaluación     | Banco de preguntas, casos ambiguos y ataques.                            |
| Acceso         | Público, enlace, miembros o roles.                                       |
| Analítica      | Solo datos necesarios, agregados y con privacidad.                       |
| Mantenimiento  | Responsable, actualización y retiro.                                     |

### 21.1 Reglas pedagógicas

- No entregar respuestas finales cuando el objetivo sea aprender el razonamiento.
- Usar preguntas socráticas y evidencia progresiva.
- Diferenciar explicar, orientar, evaluar y calificar.
- No evaluar estudiantes con criterios no divulgados.
- Permitir impugnación y revisión humana.

## 22. IA en revisiones de literatura

| Tarea           | Uso responsable                                                  |
|-----------------|------------------------------------------------------------------|
| Terminos        | Ampliar sinonimos y vocabularios; validar con fuentes y experto. |
| Busqueda        | Traducir sintaxis; verificar linea por linea.                    |
| Deduplicacion   | Detectar candidatos; auditar falsos duplicados.                  |
| Cribado         | Priorizar; controlar falsos negativos y criterio de parada.      |
| Extraccion      | Comparar con texto y doble verificar campos criticos.            |
| Riesgo de sesgo | No automatizar juicio final sin evidencia y consenso.            |
| Sintesis        | Organizar, no inventar relaciones ni magnitudes.                 |
| Citas           | Verificar DOI, titulo, autores y contenido en fuente primaria.   |

## 23. IA en investigacion cuantitativa

| Tarea            | Control                                                           |
|------------------|-------------------------------------------------------------------|
| Codigo           | Pruebas, revisiones, versiones y datos conocidos.                 |
| Limpieza         | Reglas reproducibles; no completar por intuicion.                 |
| Modelos          | Teoria, validacion y diagnosticos.                                |
| Visualizacion    | Ejes, denominadores, incertidumbre y reproducibilidad.            |
| Datos sinteticos | Etiquetar, separar y evaluar si preservan propiedades/privacidad. |
| Prediccion       | Validacion externa, calibracion, equidad y deriva.                |
| Interpretacion   | No causalizar ni exagerar significancia.                          |

## 24. IA en investigacion cualitativa y mixta

| Tarea           | Control                                               |
|-----------------|-------------------------------------------------------|
| Transcripcion   | Consentimiento, privacidad y revision contra audio.   |
| Traduccion      | Preservar significado y revisar cultura.              |
| Codificacion    | Usar como propuesta y auditar con datos.              |
| Temas           | No aceptar sin memos, casos negativos y reflexividad. |
| Anonimizacion   | Verificar identificadores contextuales.               |
| Joint displays  | No rellenar celdas sin evidencia.                     |
| Meta-inferencia | Responsabilidad humana interdisciplinaria.            |
| Representacion  | Evitar homogeneizar voces o eliminar ambigüedad.      |

## 25. Automatizacion reproducible

| Capa           | Practica                                       |
|----------------|------------------------------------------------|
| Entrada        | Validar formato, version, permisos y checksum. |
| Transformacion | Script, parametros, logs y manejo de errores.  |
| Modelo         | ID, version/fecha, configuracion y fallback.   |
| Prompt         | Versionado, pruebas y esquema de salida.       |
| Salida         | Validacion de esquema, procedencia y calidad.  |
| Humano         | Responsable, decision y cambios.               |
| Entorno        | Dependencias, contenedor o lockfile.           |
| Monitoreo      | Metricas, alertas y incidentes.                |

### 25.1 Evidencia minima por ejecucion

- Fecha/hora e identificador.
- Usuario o servicio autorizado.
- Input o referencia segura al input.
- Modelo, prompt y herramientas.
- Resultado y validaciones.
- Aprobacion o accion realizada.
- Costo, latencia y errores.

## 26. Monitoreo, deriva e incidentes

| Senal                      | Respuesta                                                  |
|----------------------------|------------------------------------------------------------|
| Caida de calidad           | Comparar con conjunto de regresion y activar fallback.     |
| Cambio de proveedor/modelo | Reevaluar antes de aprobar nueva version.                  |
| Nuevo tipo de usuario      | Revisar riesgo, accesibilidad y lenguaje.                  |
| Corpus obsoleto            | Retirar, reindexar y mostrar fecha de vigencia.            |
| Ataque o fuga              | Detener, revocar, preservar evidencia y responder.         |
| Queja o dano               | Atender, corregir, comunicar y prevenir recurrencia.       |
| Costo creciente            | Optimizar, cachear, usar modelo menor o reducir autonomia. |
| Dependencia excesiva       | Entrenar, introducir verificacion y alternativas.          |

### 26.1 Severidad

| Nivel   | Ejemplo                     | Accion                |
|---------|-----------------------------|-----------------------|
| 1 Menor | Formato incorrecto sin uso. | Corregir y registrar. |

| Nivel      | Ejemplo                                              | Accion                                             |
|------------|------------------------------------------------------|----------------------------------------------------|
| 2 Moderado | Respuesta errada detectada antes de decision.        | Analisis y prueba de regresion.                    |
| 3 Mayor    | Error usado en trabajo o dato expuesto internamente. | Suspender funcion y notificar responsables.        |
| 4 Critico  | Dano, filtracion sensible o accion externa indebida. | Detener sistema, respuesta formal e investigacion. |

## 27. Politica de supervision humana

| Tipo de decision               | Supervision minima                                           |
|--------------------------------|--------------------------------------------------------------|
| Bajo riesgo/reversible         | Revision por muestra y monitoreo.                            |
| Contenido academico publicado  | Revision completa de afirmaciones, fuentes y autoria.        |
| Analisis estadistico           | Revision de codigo, supuestos y resultados.                  |
| Clasificacion de participantes | Doble control y posibilidad de impugnacion.                  |
| Calificacion/evaluacion        | Criterios transparentes y decision humana responsable.       |
| Datos sensibles                | Autorizacion, minimizacion y registro.                       |
| Accion externa                 | Aprobacion antes de enviar/publicar/modificar.               |
| Alto impacto                   | Comite o responsable designado, alternativa no automatizada. |

### 27.1 Supervision efectiva

- Tiempo y competencia para revisar.
- Acceso a fuentes y contexto.
- Autoridad real para rechazar.
- Interfaz que muestra incertidumbre y evidencia.
- Registro de la decision humana.
- Entrenamiento sobre sesgos de automatizacion.

## 28. Madurez de adopcion de IA en SIPRAI

| Nivel        | Descripcion                                                        | Evidencia                                |
|--------------|--------------------------------------------------------------------|------------------------------------------|
| 0 Ad hoc     | Uso individual sin politica.                                       | No existe inventario.                    |
| 1 Asistido   | Casos de bajo riesgo con reglas basicas.                           | Declaracion y capacitacion.              |
| 2 Controlado | Inventario, clasificacion y evaluaciones.                          | Fichas y gates.                          |
| 3 Integrado  | Flujos reproducibles, RAG, automatizacion y monitoreo.             | Logs, dashboards y incidentes.           |
| 4 Gestionado | Sistema de gestion, auditorias y portafolio de IA.                 | Revision directiva y mejora.             |
| 5 Adaptativo | Evals continuas, aprendizaje de fallos y gobernanza participativa. | Versionado, red teaming y transferencia. |

## 29. Metricas de valor y costo total

| Dimension      | Indicadores                                                    |
|----------------|----------------------------------------------------------------|
| Calidad        | Mejora frente a linea base y tasa de error.                    |
| Tiempo         | Tiempo total incluyendo revision y correccion.                 |
| Esfuerzo       | Minutos humanos, especializacion y carga cognitiva.            |
| Costo          | Uso, infraestructura, licencias, integracion y evaluacion.     |
| Riesgo         | Incidentes, casi fallos, datos expuestos y acciones detenidas. |
| Adopcion       | Usuarios activos, tareas completadas y abandono.               |
| Equidad        | Acceso, rendimiento por grupos e idiomas.                      |
| Aprendizaje    | Nuevas competencias, reutilizacion y calidad de decisiones.    |
| Sostenibilidad | Uso de modelos adecuados, eficiencia y vida util.              |

**El ahorro bruto no es valor. Debe descontarse el tiempo de revision, correccion, gobernanza, incidentes y dependencia del proveedor.**

## 30. Gestion agil de un caso de uso de IA

|                      |                    |                       |                   |                    |                        |                       |
|----------------------|--------------------|-----------------------|-------------------|--------------------|------------------------|-----------------------|
| SPRINT 0<br>Problema | SPRINT 1<br>Riesgo | SPRINT 2<br>Prototipo | SPRINT 3<br>Evals | SPRINT 4<br>Piloto | SPRINT 5<br>Despliegue | SPRINT 6<br>Monitoreo |
|----------------------|--------------------|-----------------------|-------------------|--------------------|------------------------|-----------------------|

| Sprint       | Definition of Done                                         |
|--------------|------------------------------------------------------------|
| 0 Problema   | Usuario, tarea, alternativa y valor observable.            |
| 1 Riesgo     | Datos, nivel, impactos, amenazas y responsables.           |
| 2 Prototipo  | Arquitectura minima, prompts, permisos y logs.             |
| 3 Evals      | Dataset, linea base, rubrica, ataques y umbrales.          |
| 4 Piloto     | Usuarios reales, supervision, feedback y no conformidades. |
| 5 Despliegue | Aprobacion, soporte, version y fallback.                   |
| 6 Monitoreo  | Metricas, incidentes, cambio y retiro.                     |

### 30.1 Limites WIP

- No abrir multiples agentes antes de evaluar un copiloto simple.
- No conectar herramientas externas antes de probar solo lectura.
- No escalar sin conjunto de regresion.
- No automatizar una decision que el equipo no entiende.

## 31. Puertas de calidad SIPRAI

| Puerta               | Pregunta                                                  | Evidencia                          |
|----------------------|-----------------------------------------------------------|------------------------------------|
| A0 Necesidad         | ¿La IA es necesaria y superior a una alternativa simple?  | Caso de uso y linea base.          |
| A1 Gobernanza        | ¿Existe responsable, política y clasificacion?            | Ficha e inventario.                |
| A2 Datos             | ¿Permisos, calidad y privacidad son adecuados?            | Evaluacion de datos.               |
| A3 Diseno            | ¿Arquitectura, permisos y supervision son proporcionales? | Diagrama y controles.              |
| A4 Integridad        | ¿Autoria, divulgacion, citas y propiedad estan resueltas? | Declaracion y checklist.           |
| A5 Evaluacion        | ¿Hay conjunto, rubrica, comparador y umbrales?            | Informe TEVV.                      |
| A6 Seguridad         | ¿Se probaron ataques y fallos?                            | Red team y mitigaciones.           |
| A7 Piloto            | ¿Funciona con usuarios y contexto reales?                 | Informe de piloto.                 |
| A8 Despliegue        | ¿Version, soporte, fallback y accesos estan listos?       | Acta Go/No-Go.                     |
| A9 Monitoreo         | ¿Metricas, alertas e incidentes estan operativos?         | Dashboard y registro.              |
| A10 Reproducibilidad | ¿Puede reconstruirse el flujo?                            | Logs, prompts, código y versiones. |
| A11 Valor            | ¿Produce mejora neta y aprendizaje?                       | Evaluacion de outcomes.            |

## 32. Rubrica de IA responsable - escala 1 a 5

| Criterio    | 1                     | 2                        | 3                   | 4                             | 5                                               |
|-------------|-----------------------|--------------------------|---------------------|-------------------------------|-------------------------------------------------|
| Necesidad   | IA por moda           | Beneficio supuesto       | Caso basico         | Linea base y valor            | IA indispensable, proporcional y medible        |
| Gobernanza  | Sin responsable       | Reglas informales        | Ficha basica        | Inventario y gates            | Sistema de gestion y auditoria                  |
| Datos       | Se cargan sin control | Privacidad ambigua       | Minimizacion basica | Permisos y seguridad          | Procedencia, derechos y evaluacion de impacto   |
| Diseno      | Prompt aislado        | Flujo fragil             | Arquitectura basica | Permisos y fallback           | Diseno modular, observable y portatil           |
| Evaluacion  | Prueba anecdotica     | Ejemplos favorables      | Rubrica basica      | Benchmark local y ataques     | TEVV continuo, campo y equidad                  |
| Integridad  | No se declara         | Revision superficial     | Divulgacion basica  | Citas y responsabilidad       | Trazabilidad completa y auditoria               |
| Supervision | Humano nominal        | Revision tardia          | Aprobacion puntual  | Puntos criticos y competencia | Supervision efectiva, impugnacion y alternativa |
| Agentes     | Autonomia amplia      | Herramientas sin limites | Lectura controlada  | Permisos minimos              | Acciones reversibles, logs y parada segura      |
| Monitoreo   | No existe             | Quejas informales        | Metricas basicas    | Alertas e incidentes          | Regresion, deriva y mejora continua             |
| Valor       | Mas velocidad         | Ahorro bruto             | Beneficio parcial   | Valor neto medido             | Calidad, equidad, aprendizaje y sostenibilidad  |

### 33. Errores frecuentes y correcciones

| Error                                   | Consecuencia                                | Correccion                              |
|-----------------------------------------|---------------------------------------------|-----------------------------------------|
| El modelo suena seguro                  | Se confunde fluidez con verdad.             | Exigir evidencia y evals.               |
| Citar al chatbot                        | No hay fuente estable ni autor responsable. | Citar fuentes originales.               |
| RAG elimina alucinaciones               | Falsa garantia.                             | Evaluar groundedness y citas.           |
| Modelo mas grande siempre mejor         | Costo/latencia y riesgo innecesarios.       | Benchmark local y modelo suficiente.    |
| Agente para tarea simple                | Complejidad y superficie de ataque.         | Automatizacion determinista o copiloto. |
| Prompts como propiedad secreta          | No reproducible.                            | Versionar y documentar.                 |
| Revision humana simbolica               | Sesgo de automatizacion.                    | Tiempo, autoridad y evidencia.          |
| Datos institucionales en cuenta publica | Exposicion y incumplimiento.                | Entorno aprobado y minimizacion.        |
| IA como autora                          | Responsabilidad inexistente.                | Autores humanos y divulgacion.          |
| Evals con cinco ejemplos                | Sobreajuste.                                | Conjunto representativo y adversarial.  |
| Juez IA sin calibrar                    | Sesgo oculto.                               | Comparar con expertos.                  |
| Actualizar modelo sin probar            | Regresion silenciosa.                       | Versionado y suite de pruebas.          |
| Memoria sin politica                    | Retencion y contaminacion.                  | Definir necesidad y borrado.            |
| Automatizar calificacion                | Dano y falta de impugnacion.                | Criterios, revision y alternativa.      |
| No medir costo de correccion            | ROI falso.                                  | Costo total y valor neto.               |

### 34. Ejemplos aplicados a las lineas SIPRAI

| Linea          | Caso                                             | Controles                                 | Resultado                                      |
|----------------|--------------------------------------------------|-------------------------------------------|------------------------------------------------|
| Proyectos      | Copiloto que identifica vacios en oportunidades. | RAG + rubrica + aprobacion humana.        | Mejor preparacion sin decidir portafolio.      |
| Agilidad       | Agente que resume flujo y propone experimento.   | Solo lectura, limites y Review.           | Aprendizaje, no gestion automatica del equipo. |
| Emprendimiento | Clasificador de evidencia de clientes.           | Taxonomia validada y auditoria.           | Distingue declaracion de conducta.             |
| IA             | Laboratorio de evaluacion de asistentes.         | TEVV, red team y benchmark local.         | Conocimiento sobre gobernanza.                 |
| Equipos        | Analisis de reuniones para patrones.             | Consentimiento, privacidad y cualitativo. | No etiquetar personalidad.                     |
| Educacion      | GPT tutor de proyectos.                          | Corpus, citas, socratico y revision.      | Aprendizaje con integridad.                    |
| Territorio     | Asistente multilingue para consulta comunitaria. | CARE, control local y acceso.             | Inclusion sin extraer datos.                   |

## 35. Directrices para el GPT mentor

| Solicitud                     | Respuesta obligatoria                                                                    |
|-------------------------------|------------------------------------------------------------------------------------------|
| “Busca y cita articulos”      | No inventar; usar fuentes verificables y distinguir busqueda de memoria.                 |
| “Haz el analisis completo”    | Pedir datos, objetivo, metodo y controles; entregar codigo/revision, no autoridad final. |
| “Crea un agente autonomo”     | Definir meta, herramientas, permisos, aprobaciones, parada y evals.                      |
| “Subire entrevistas”          | Revisar consentimiento, privacidad, plataforma y anonimizar.                             |
| “Dime si este texto es de IA” | Advertir limites de detectores y no acusar sin evidencia.                                |
| “Califica estudiantes”        | Exigir rubrica, transparencia, revision humana y mecanismo de apelacion.                 |
| “La respuesta trae citas”     | Verificar que cada cita sustente la afirmacion.                                          |
| “Guarda esto en memoria”      | Confirmar necesidad, sensibilidad y alcance antes de persistir.                          |
| “Usa el mejor modelo”         | Solicitar tarea, riesgo, datos, costo y benchmark local.                                 |
| “No menciones que use IA”     | Rechazar ocultamiento cuando la divulgacion sea material o exigida.                      |
| “Completa datos faltantes”    | No fabricar; aplicar metodo valido o marcar ausencia.                                    |
| “Publica automaticamente”     | Requerir aprobacion humana antes de accion externa.                                      |

## 36. Referentes normativos y metodologicos

NIST. (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0), NIST AI 100-1.

NIST. (2024). Artificial Intelligence Risk Management Framework: Generative Artificial Intelligence Profile, NIST AI 600-1.

NIST. AI Test, Evaluation, Validation and Verification (TEVV) resources and AI Resource Center.

UNESCO. (2021). Recommendation on the Ethics of Artificial Intelligence.

UNESCO. (2023). Guidance for Generative AI in Education and Research.

OECD. (2019, updated 2024). Recommendation of the Council on Artificial Intelligence / OECD AI Principles.

ISO/IEC 42001:2023. Information technology - Artificial intelligence - Management system.

ISO/IEC 42006:2025. Requirements for bodies providing audit and certification of AI management systems.

European Union. Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence.

Departamento Nacional de Planeacion. (2025). Documento CONPES 4144 - Politica Nacional de Inteligencia Artificial.

Superintendencia de Industria y Comercio. (2024). Circular Externa 002 - Lineamientos sobre tratamiento de datos personales en sistemas de inteligencia artificial.

Committee on Publication Ethics. (2023). Authorship and AI tools.

International Committee of Medical Journal Editors. Recommendations: Use of Artificial Intelligence in Publishing, version vigente.

Mitchell, M. et al. (2019). Model Cards for Model Reporting. FAT\*.

Geburu, T. et al. (2021). Datasheets for Datasets. Communications of the ACM.

Raji, I. D. et al. (2020). Closing the AI Accountability Gap: Defining an End-to-End Framework for Internal Algorithmic Auditing.

Liang, P. et al. (2022). Holistic Evaluation of Language Models (HELM).

Lewis, P. et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks.

OWASP Foundation. Top 10 for Large Language Model Applications, version vigente.

Wilkinson, M. D. et al. (2016). FAIR Guiding Principles for scientific data management and stewardship.

## Anexo A. Canvas de caso de uso de IA

| Campo                      | Decision |
|----------------------------|----------|
| Problema/usuario           |          |
| Tarea y alternativa sin IA |          |
| Valor esperado             |          |
| Nivel de autonomia         |          |
| Datos y permisos           |          |
| Modelo/proveedor           |          |
| Herramientas/conectores    |          |
| Riesgos e impactos         |          |
| Supervision                |          |
| Evaluacion/umbrales        |          |
| Despliegue/monitoreo       |          |
| Retiro/fallback            |          |

## Anexo B. Evaluacion de riesgo e impacto

| Dimension                  | Bajo | Medio | Alto | Evidencia/mitigacion |
|----------------------------|------|-------|------|----------------------|
| Impacto sobre personas     |      |       |      |                      |
| Datos personales/sensibles |      |       |      |                      |
| Autonomia/acciones         |      |       |      |                      |
| Reversibilidad             |      |       |      |                      |
| Opacidad                   |      |       |      |                      |
| Probabilidad de error      |      |       |      |                      |
| Detectabilidad             |      |       |      |                      |
| Equidad/accesibilidad      |      |       |      |                      |
| Seguridad                  |      |       |      |                      |
| Dependencia proveedor      |      |       |      |                      |

## Anexo C. Ficha del sistema/modelo

| Campo                          | Registro |
|--------------------------------|----------|
| Nombre e ID                    |          |
| Propietario/responsable        |          |
| Proveedor/modelo/version-fecha |          |
| Proposito y usuarios           |          |
| Datos/corpus                   |          |
| Arquitectura y herramientas    |          |
| Capacidades                    |          |
| Limites/usos prohibidos        |          |
| Metricas/evals                 |          |
| Riesgos/controles              |          |
| Accesos/logs                   |          |
| Fecha de revision/retiro       |          |

## Anexo D. Tarjeta de prompt

| Campo                   | Contenido |
|-------------------------|-----------|
| ID/version              |           |
| Tarea                   |           |
| Rol funcional           |           |
| Contexto/fuentes        |           |
| Instrucciones           |           |
| Herramientas            |           |
| Esquema de salida       |           |
| Criterios de calidad    |           |
| Abstencion/escalamiento |           |
| Datos prohibidos        |           |
| Ejemplos de prueba      |           |
| Responsable/cambios     |           |

Anexo E. Plan de evaluacion TEVV

| Campo                  | Decision |
|------------------------|----------|
| Objetivo/uso           |          |
| Linea base/comparador  |          |
| Poblacion de tareas    |          |
| Dataset de evaluacion  |          |
| Rubrica/metricas       |          |
| Casos limite           |          |
| Casos adversariales    |          |
| Evaluacion humana      |          |
| Evaluacion automatica  |          |
| Umbrales Go/No-Go      |          |
| Analisis por subgrupos |          |
| Limitaciones/revision  |          |

Anexo F. Banco de casos de evaluacion

| ID | Caso/input | Resultado esperado | Riesgo | Criterios | Estado |
|----|------------|--------------------|--------|-----------|--------|
|    |            |                    |        |           |        |
|    |            |                    |        |           |        |
|    |            |                    |        |           |        |
|    |            |                    |        |           |        |
|    |            |                    |        |           |        |
|    |            |                    |        |           |        |

Anexo G. Checklist RAG

| Control                     | Si/No/NA | Evidencia |
|-----------------------------|----------|-----------|
| Corpus autorizado y vigente |          |           |
| Extraccion verificada       |          |           |
| Chunking justificado        |          |           |
| Metadatos y permisos        |          |           |

| Control                  | Si/No/NA | Evidencia |
|--------------------------|----------|-----------|
| Recuperacion evaluada    |          |           |
| Reranking probado        |          |           |
| Citas trazables          |          |           |
| Contradicciones tratadas |          |           |
| Abstencion               |          |           |
| Prompt injection         |          |           |
| Actualizacion/versionado |          |           |
| Conjunto de regresion    |          |           |

## Anexo H. Especificacion de agente

| Campo                    | Decision |
|--------------------------|----------|
| Meta/criterio de exito   |          |
| Nivel de autonomia       |          |
| Herramientas permitidas  |          |
| Permisos por herramienta |          |
| Memoria/retencion        |          |
| Planificacion/max pasos  |          |
| Aprobaciones humanas     |          |
| Limites costo/tiempo     |          |
| Validacion de acciones   |          |
| Fallback/parada          |          |
| Logs/observabilidad      |          |
| Riesgos/pruebas          |          |

## Anexo I. Checklist de supervision humana

| Control                  | Si/No/NA | Evidencia |
|--------------------------|----------|-----------|
| Responsable identificado |          |           |
| Competencia para revisar |          |           |
| Tiempo suficiente        |          |           |

| Control                                  | Si/No/NA | Evidencia |
|------------------------------------------|----------|-----------|
| Fuentes disponibles                      |          |           |
| Incertidumbre visible                    |          |           |
| Autoridad para rechazar                  |          |           |
| Punto de aprobacion                      |          |           |
| Alternativa manual                       |          |           |
| Registro de decision                     |          |           |
| Mecanismo de apelacion                   |          |           |
| Entrenamiento en sesgo de automatizacion |          |           |

## Anexo J. Declaracion de uso de IA

| Campo                         | Texto |
|-------------------------------|-------|
| Herramienta/modelo/fecha      |       |
| Tarea                         |       |
| Datos o materiales procesados |       |
| Procedimiento de verificacion |       |
| Cambios humanos               |       |
| Prompts/codigo disponibles    |       |
| Limitaciones                  |       |
| Responsabilidad autoral       |       |

## Anexo K. Registro de incidentes

| Fecha | Sistema | Severidad | Descripcion | Impacto | Contencion | Causa | Accion |
|-------|---------|-----------|-------------|---------|------------|-------|--------|
|       |         |           |             |         |            |       |        |
|       |         |           |             |         |            |       |        |
|       |         |           |             |         |            |       |        |
|       |         |           |             |         |            |       |        |
|       |         |           |             |         |            |       |        |

## Anexo L. Registro de cambios y regresion

| Version/fecha | Cambio | Motivo | Evals ejecutadas | Resultado | Aprobacion | Rollback |
|---------------|--------|--------|------------------|-----------|------------|----------|
|               |        |        |                  |           |            |          |
|               |        |        |                  |           |            |          |
|               |        |        |                  |           |            |          |
|               |        |        |                  |           |            |          |
|               |        |        |                  |           |            |          |

## Anexo M. Matriz de proveedor/modelo

| Criterio                | Opcion A | Opcion B | Opcion C | Decision/racional |
|-------------------------|----------|----------|----------|-------------------|
| Calidad local           |          |          |          |                   |
| Privacidad/retencion    |          |          |          |                   |
| Seguridad               |          |          |          |                   |
| Versionado/control      |          |          |          |                   |
| Herramientas/modalidad  |          |          |          |                   |
| Costo total             |          |          |          |                   |
| Latencia/disponibilidad |          |          |          |                   |
| Portabilidad            |          |          |          |                   |
| Sostenibilidad          |          |          |          |                   |
| Soporte                 |          |          |          |                   |

## Anexo N. Dashboard de IA responsable

| Indicador              | Definicion | Meta | Frecuencia | Fuente | Responsable |
|------------------------|------------|------|------------|--------|-------------|
| Calidad vs linea base  |            |      |            |        |             |
| Groundedness/citas     |            |      |            |        |             |
| Tasa de abstencion     |            |      |            |        |             |
| Fallos de seguridad    |            |      |            |        |             |
| Incidentes/casi fallos |            |      |            |        |             |
| Tiempo total           |            |      |            |        |             |
| Costo total            |            |      |            |        |             |

| Indicador        | Definicion | Meta | Frecuencia | Fuente | Responsable |
|------------------|------------|------|------------|--------|-------------|
| Carga humana     |            |      |            |        |             |
| Equidad/acceso   |            |      |            |        |             |
| Satisfaccion/uso |            |      |            |        |             |

## Anexo O. Checklist de cierre y retiro

| Control                              | Si/No/NA | Evidencia |
|--------------------------------------|----------|-----------|
| Objetivo cumplido/evaluado           |          |           |
| Datos y permisos cerrados            |          |           |
| Credenciales revocadas               |          |           |
| Logs y versiones archivados          |          |           |
| Incidentes resueltos                 |          |           |
| Declaraciones publicadas             |          |           |
| Exportacion/portabilidad             |          |           |
| Proveedor y contratos cerrados       |          |           |
| Usuarios comunicados                 |          |           |
| Lecciones aprendidas                 |          |           |
| Riesgos residuales                   |          |           |
| Decision mantener/reemplazar/retirar |          |           |

## Anexo P. Guion de clinica de IA para investigacion

1. Definir el problema y demostrar por que IA agrega valor.
2. Clasificar tarea, datos, impacto y autonomia.
3. Presentar arquitectura, modelo, herramientas y permisos.
4. Mostrar prompt o especificacion versionada.
5. Presentar conjunto de evaluacion, linea base y umbrales.
6. Demostrar un fallo, un caso adversarial y su mitigacion.
7. Mostrar supervision humana, logs y fallback.
8. Revisar privacidad, autoria, citas, equidad y normativa.
9. Calcular valor neto, costo total y carga de revision.
10. Decidir Go, Adjust, Hold, Stop o Retire con accion verificable.

### Etiquetas de recuperacion para el GPT

#IA\_investigacion #GenAI #copilotos #agentes #RAG #evaluacion\_IA #TEVV #NIST\_AI\_RMF #ISO42001  
 #UNESCO\_AI #OECD\_AI #AI\_Act #CONPES4144 #SIC\_IA\_datos #prompting #groundedness #model\_cards  
 #human\_oversight #AI\_governance #AI\_incidents #SIPRAI